División de datos

Cómo saber si un modelo podrá clasificar un correo nuevo

Dividir los datos significa repartir los ejemplos disponibles en grupos antes de construir el modelo. Usamos unos para aprender, otros para elegir y otros para comprobar el resultado.

Fabiana Leonardo Rufino

Qué son los datos en este ejemplo

Un conjunto de datos es una colección de ejemplos. En esta tabla, cada fila describe un correo completo.

Asunto del correo	¿Tiene enlace?	Clasificación conocida
Oferta gratis por tiempo limitado	Sí	Spam
Cambio de horario del lunes	No	Normal

La clasificación conocida se llama etiqueta. «Spam» significa correo no deseado.

Qué es un modelo y qué aprende

Un modelo usa pistas que conocemos para predecir una respuesta que aún desconocemos.

Lo que recibe	El asunto dice «Oferta gratis» y el mensaje contiene un enlace.
Lo que aprende	En los correos antiguos busca una relación entre esas pistas y las etiquetas.
Lo que predice	Al llegar otro mensaje, aplica la regla aprendida y responde «spam» o «normal».

Una predicción puede equivocarse. Para saber cuándo ocurre, necesitamos ejemplos nuevos.

Qué se divide exactamente

Dividimos las filas de la tabla. Cada correo, con sus pistas y su etiqueta, queda en un solo grupo.

6

Para aprender

Correos 01 a 06

3

Para elegir

Correos 07 a 09

3

Para evaluar

Correos 10 a 12

Son doce correos ficticios. Los repartimos antes de empezar y reservamos los tres últimos para la evaluación final.

Por qué guardamos ejemplos para después

Un examen repite las mismas preguntas que la estudiante resolvió ayer. Una nota alta podría deberse a que recuerda las respuestas.

Con un modelo ocurre algo parecido. Si medimos sus aciertos con los mismos correos que le enseñaron la regla, la nota solo cuenta cómo respondió ante mensajes conocidos.

Para estimar cómo responderá mañana, hoy le reservamos correos que no intervienen en el aprendizaje ni en la elección.

Why do we split data?

A dataset is a collection of examples. Each row in our dataset represents one email.

Past emails have labels. We use some of them to learn a rule and keep other emails for later. This helps us check whether the rule works on messages it has never seen.

En español: reservamos mensajes conocidos para simular la llegada de mensajes nuevos.

Qué decisión se toma con cada grupo

Cada grupo cumple una función. Su nombre indica qué podemos decidir a partir de sus correos.

Conjunto	Qué hacemos	Qué obtenemos
Entrenamiento · Training	Buscamos patrones en ejemplos etiquetados.	Reglas candidatas
Validación · Validation	Comparamos reglas con los mismos correos nuevos.	Una regla elegida
Prueba · Test	Aplicamos la elegida a correos reservados.	Una medida final

Es el orden de un curso: ejercicios resueltos para aprender, simulacro para escoger una estrategia y examen final para evaluarla.

Entrenamiento · Cómo surgen dos reglas

En los seis correos de entrenamiento, los tres de spam contienen «gratis» y un enlace. Los tres normales no contienen «gratis».

Regla A	Marca un correo como spam si aparece la palabra «gratis».
Regla B	Marca spam únicamente si aparece «gratis» y también hay un enlace.
Resultado	Las dos reglas aciertan 6 de 6. Con estos mensajes todavía no sabemos cuál funcionará mejor.

Para simplificar, las reglas se muestran a mano. Un algoritmo puede aprender patrones más complejos con muchos más datos.

Validación · El mensaje que decide la elección

Aplicamos A y B a los mismos tres correos de validación. La etiqueta real permite corregir sus predicciones.

Asunto	Enlace	Regla A	Regla B	Real
Actividad gratis en la biblioteca	No	Spam	Normal	Normal
Cupón gratis	Sí	Spam	Spam	Spam
Acta de la reunión	Sí	Normal	Normal	Normal

A acierta 2 de 3. B acierta 3 de 3. Elegimos B porque reconoce la invitación legítima de la biblioteca.

Validation helps us choose a rule

Both rules worked on the training emails. The library email showed us how the rules behave differently.

Rule A marked the invitation as spam because it said “free”. Rule B also looked for a link. There was no link, so B let the message through. We chose rule B using validation data.

En español: «gratis» puede aparecer en un correo legítimo. La validación nos permitió elegir B antes de abrir la prueba.

Prueba · Qué pasó con la regla elegida

Abrimos los tres últimos correos. B mantiene su condición: marca spam si encuentra «gratis» y un enlace.

Asunto del mensaje nuevo	Enlace	B predice	Etiqueta real
Guía gratis de la biblioteca	Sí	Spam	Normal
Premio gratis esta semana	Sí	Spam	Spam
Factura de octubre	Sí	Normal	Normal

B acierta 2 de 3 en prueba. Su error fue enviar una guía legítima a la carpeta de spam.

What does “two out of three” mean?

The chosen rule classified two of the three test emails correctly. It sent one useful library message to spam.

Three emails are too few to predict next month’s accuracy with confidence. Reporting the count and describing the error tells us more than giving a percentage alone.

En español: dos aciertos de tres describen lo que ocurrió en esta pequeña muestra. Un solo correo cambiaría mucho la cifra.

Cuántos correos reservar para cada grupo

Con 100 correos, un reparto posible es 70 para entrenamiento, 15 para validación y 15 para prueba. Las proporciones pueden cambiar.

70

Entrenamiento

Más ejemplos para aprender patrones.

15

Validación

Otros correos para comparar opciones.

15

Prueba

Una muestra aparte para medir el resultado.

El tamaño real importa. En 15 correos de prueba, un solo acierto cambia la nota unos 6,7 puntos porcentuales.

Cómo hacer comparable el reparto

Para comparar dos filtros, conviene que ambos reciban los mismos correos y que los grupos incluyan los tipos de mensaje que nos interesan.

Estratificar	Mantener aproximadamente la proporción de spam. Si 10 de 100 correos son spam, en un grupo de 20 esperamos unos 2.
Fijar una semilla	Permite repetir el sorteo si se mantienen los datos, el orden y el procedimiento. En scikit-learn se llama random_state.

Una semilla repite un sorteo. La estratificación ayuda a que los tipos de correo estén representados.

Sobreajuste y memorización

Hay sobreajuste cuando un modelo aprende detalles muy específicos del entrenamiento y pierde eficacia con mensajes distintos.

Un filtro podría memorizar direcciones concretas que enviaron spam. Acertaría al verlas otra vez y podría fallar cuando el mismo tipo de engaño llega desde una dirección nueva.

Muchos aciertos en entrenamiento y bastantes menos en validación son una señal que conviene investigar.

Fuga de información · La respuesta se cuela

Hay fuga de información cuando el modelo o quien lo elige usa una pista que no tendría al clasificar un correo realmente nuevo.

La carpeta final — Usar «carpeta donde el usuario lo guardó» daría una pista del resultado. Esa información llega después de la predicción.

La prueba reutilizada — Añadir una excepción al ver el error de la biblioteca hace que ese correo de prueba influya en la nueva regla.

Para medir la regla modificada de forma independiente hacen falta otros correos reservados.

What makes a test fair?

A fair test reflects what the filter can know when a new email arrives.

The subject is available immediately. The user's final folder is only known later. If we use that folder as a clue, the filter gets access to part of the answer before it makes its prediction.

En español: una evaluación justa usa solo la información disponible en el momento de decidir.

Validación cruzada · Varios simulacros

Apartamos el test final. Dividimos los correos de desarrollo en tres bloques y cambiamos cuál actúa como validación.

Vuelta	Se aprende con	Se valida con
1	Bloques B y C	Bloque A
2	Bloques A y C	Bloque B
3	Bloques A y B	Bloque C

Se vuelve a entrenar en cada vuelta. Así podemos observar cuánto cambia el resultado entre bloques antes de elegir el filtro.

Cuando queremos predecir el mes siguiente

Si el objetivo es filtrar correos que llegarán en el futuro, el reparto debe respetar la fecha. Las campañas de spam cambian con el tiempo.

Ene–abr

Entrenamiento

Aprendemos con los mensajes más antiguos.

Mayo

Validación

Elegimos la regla con mensajes posteriores.

Junio

Prueba

La evaluamos en el último período reservado.

Mezclar junio en el entrenamiento para evaluar febrero daría al filtro información que aún no existía en febrero.

How I would report the result

“We chose rule B using validation data. On three separate test emails, it made two correct predictions.”

“The error was a useful library email sent to spam. Before using this filter in a real inbox, I would test it on more messages from the people who will use it.”

En español: un resultado se entiende mejor cuando indicamos qué elegimos, con cuántos casos lo medimos y qué error apareció.

Qué significa dividir los datos

Separamos los ejemplos antes de construir el filtro.
Cada grupo contesta una pregunta distinta.

Entrenamiento: ¿qué patrón podemos aprender?
Validación: ¿qué regla conviene elegir?
Prueba: ¿cómo funciona con correos nuevos?

github.com/fabileoruf/taller-division-de-datos

