División de datos

Entrenamiento, validación y prueba

Fabiana Leonardo Rufino

Cuaderno y ficha

¿Le darías el aprobado?

30 de 30

Un modelo reconoce las 30 flores con las que practicó.
Mañana tendrá que identificar una flor nueva.

En parejas: ¿qué prueba le pediríais antes de confiar en él?

Tres conjuntos, tres decisiones

Entrenamiento

Train

Los ejercicios

El modelo aprende de los ejemplos y sus etiquetas.

Validación

Validation

El simulacro

Comparamos opciones y elegimos una.

Prueba

Test

El examen final

Medimos el rendimiento con ejemplos reservados.

¿Dónde probarías dos configuraciones antes de elegir una?

150 flores para el taller

¿Qué especie es?

Cada fila contiene cuatro medidas:
la longitud y la anchura del sépalo
y del pétalo, en centímetros.

50 setosa · 50 versicolor · 50 virginica

Reservamos 30 flores para el examen final.



El reparto de Iris

90

Entrenamiento

30 por especie

30

Validación

10 por especie

30

Prueba

10 por especie

Primero reservamos 30 de 150. Después separamos 30 de las 120 restantes.

stratify conserva las proporciones de clase. La semilla fija permite repetir el reparto.

¿Cuándo se calcula la media?

El escalado usa la media y la dispersión de cada medida.

```
modelo = make_pipeline(
    StandardScaler(),
    LogisticRegression(C=1, max_iter=1000)
)
modelo.fit(X[train], y[train])
```

Si ajustamos el escalador con las 150 flores, ¿qué información se filtra?

La decisión se toma en validación

Dos regresiones logísticas. Solo cambia C, que controla la regularización.

C = 0,01

24 / 30

C = 1

28 / 30

Anotad qué configuración enviaríais al examen y justificad la elección.

El examen de las 30 flores

28 de 30

El modelo elegido acertó el 93,3 % de la muestra reservada.

Con solo 30 flores, ¿cuánto cambia la nota por un acierto?

Validación cruzada con cinco pliegues

El test queda aparte. Repartimos los 120 ejemplos de desarrollo en cinco grupos.

Vuelta 1	**1 valida**	2, 3, 4 y 5 entrenan
Vuelta 2	**2 valida**	1, 3, 4 y 5 entrenan

Tras cinco vueltas, cada grupo ha validado una vez. Comparamos las medias.

Which model goes to the final test?

One model got 24 flowers right.
The other got 28 right.
Both scores came from the validation set.

When should we open the test set?

Detectives de datos

Cada equipo investiga un caso. Tenéis siete minutos para preparar una defensa.

A	**Invernadero**	Dos fotos de una planta acaban en conjuntos distintos.
B	**Panadería**	Se mezclan ventas de enero a junio para predecir julio.
C	**Devoluciones**	Al cobrar, el modelo usa la fecha de reembolso.

En la ficha: señalad una pista, proponed un cambio y decidid cómo comprobarlo.

La investigación del equipo

2 min **La pista** — Subrayad el dato que delata el problema.

3 min **La reparación** — Proponed un cambio en la división o en las variables.

2 min **La prueba** — Describid una condición que se pueda verificar.

Preparad una defensa de 45 segundos con vuestro caso y vuestra decisión.

La defensa de cada caso

«La pista es ___. Cambiaríamos ___.
Sabríamos que funciona si ___.»

Quien escucha puede pedir una prueba más.

Tres comprobaciones para el informe

A	**Plantas**	Ninguna planta aparece en dos conjuntos.
B	**Fechas**	Enero a abril para entrenar, mayo para validar y junio para la prueba.
C	**Reembolsos**	Quitamos la fecha de reembolso. Solo usamos variables disponibles al cobrar.

¿Qué cambio haríais primero en vuestro caso?

Antes de salir

Mañana añadimos otra foto de una planta
que ya está en entrenamiento.
¿Dónde la pondrías y por qué?

“We kept the test set separate because…”

github.com/fabileoruf/taller-division-de-datos