División de datos

Entrenamiento, validación y prueba

Repartimos los ejemplos en tres grupos: uno para aprender, otro para elegir y otro para medir el resultado final.

Fabiana Leonardo Rufino

Una fila representa una flor

Una observación del conjunto Iris

Longitud del pétalo: 4,0 cm

Especie conocida: versicolor



En una flor nueva conocemos la medida y queremos predecir la especie.

Qué aprende un modelo

El modelo relaciona una medida conocida
con la especie que queremos identificar.

Por ejemplo, podría predecir virginica cuando
el pétalo supera cierta longitud.

Generalizar significa acertar también con flores nuevas.

Por qué separamos los ejemplos

Un examen repite exactamente
las preguntas que ya has estudiado.

Una nota alta puede reflejar que recuerdas las respuestas.

Dividimos los datos antes de entrenar para poder evaluar con ejemplos que el modelo aún no ha visto.

Las tres partes del conjunto de datos

Conjunto	Como en un examen	Su función
Entrenamiento	Ejercicios resueltos	Aprender una regla
Validación	Simulacro	Elegir entre reglas
Prueba	Examen final	Medir el resultado

Cada ejemplo completo pertenece a un solo grupo.

Entrenamiento · Aprender una regla

Especie conocida	Longitudes de los pétalos
Versicolor	4,0 cm 4,4 cm 4,7 cm
Virginica	5,1 cm 5,5 cm 5,8 cm

A predice virginica desde 4,8 cm.

B predice virginica desde 5,0 cm.

Por debajo del corte, ambas predicen versicolor. Las dos aciertan las seis flores.

Validación · Elegir entre dos reglas

Las dos reglas se comparan con las mismas tres flores nuevas.

Regla A

2 de 3

Regla B

3 de 3

Elegimos B. La nota de validación ha servido para tomar una decisión.

Prueba · Medir el resultado final

2 de 3

flores de prueba identificadas correctamente por B.

La flor de 4,8 cm era virginica. B predijo versicolor.

Esta nota describe tres flores reservadas para el examen final.

Qué proporción reservar

Nuestro ejemplo

6 / 3 / 3

Otro reparto posible

70 / 15 / 15

En orden: entrenamiento, validación y prueba.

Los tamaños dependen de cuántos ejemplos hay y de qué casos deben representar.

Un reparto que podamos comparar

Estratificación

Conservar aproximadamente la proporción de especies en cada grupo.

Semilla fija

Repetir el reparto aleatorio con los mismos datos, el mismo orden y el mismo procedimiento.

En un grupo de 20: 18 flores de una especie (90 %) y 2 de la otra (10 %).

Sobreajuste · Cuando aprender de memoria engaña

La regla aprende detalles de las flores conocidas
que no se repiten en las flores nuevas.

Una señal posible

Muchos aciertos en entrenamiento y bastantes menos en validación.

Un solo error en una muestra de tres flores no basta para diagnosticar sobreajuste.

Fuga de información · Mirar el examen antes

La prueba revela que B falló con la flor de 4,8 cm.

Si cambiamos el corte para acertar esa flor, su respuesta ya ha influido en la regla.

Para evaluar la regla modificada hacen falta flores nuevas.

Validación cruzada · Turnarse para validar

El test final queda aparte. Rotamos solo los datos de desarrollo.

Vuelta	Entrenamiento	Validación
1	Bloques B y C	Bloque A
2	Bloques A y C	Bloque B
3	Bloques A y B	Bloque C

Cada bloque valida una vez. Comparamos los resultados de las tres vueltas.

Cuando importa la fecha

El vivero quiere reconocer las flores que llegarán el mes próximo.

Enero a abril	Mayo	Junio
Entrenamiento	Validación	Prueba

Evaluamos en fechas posteriores a las que el modelo usó para aprender.

Training, validation and test

Training	We learn a rule from known examples.
Validation	We choose between possible rules.
Test	We check the chosen rule on new flowers.

Qué significa la nota final

B acertó dos de tres flores nuevas.

Aprendimos con seis flores. Elegimos con otras tres.
Solo entonces medimos el resultado en las tres de prueba.

github.com/fabileoruf/taller-division-de-datos